FarmTech Solutions - Fase 6

Nome(s) completo(s) e RM(s): PREENCHER ANTES DA ENTREGA.

Versão corrigida em 6 de outubro de 2026. Valores de inferência e treinamento são evidências fornecidas no projeto original; nesta revisão foram recalculados F1 macro e melhor época da CNN a partir dos dados salvos. Os treinamentos não foram repetidos.

Resumo

O experimento compara três abordagens para visão computacional sobre duas classes de objetos: **garrafa (bottle)** e **xícara de café (coffee cup)**. Foi usado um recorte público de 80 imagens rotuladas do Open Images, com partição por imagem de 64/8/8 para treino/validação/teste e 32/4/4 imagens por classe em treino/validação/teste. Foram treinados dois detectores YOLOv5n com pesos COCO pré-treinados, por 30 e 60 épocas; avaliou-se ainda o YOLOv5n COCO sem ajuste fino e uma CNN convolucional treinada do zero para classificar a imagem inteira.

Na validação, o YOLO de 60 épocas superou o de 30: mAP@0,50 de 0,850 contra 0,599 e mAP@0,50:0,95 de 0,542 contra 0,328. No teste, o YOLO de 60 épocas teve mAP@0,50:0,95 de 0,411 (avaliação nativa do YOLOv5). Na comparação harmonizada em teste, mAP@0,50 foi 0,657 para 60 épocas e 0,551 para 30; o YOLO COCO sem ajuste marcou 0,676. A CNN obteve 75% de acurácia (6/8 imagens) e F1 macro de 0,75. A amostra de teste é pequena; os números servem como demonstração, não como estimativa confiável de desempenho em produção.

1. Contexto e objetivo

A FarmTech Solutions ampliou sua atuação em IA e pretende demonstrar a um cliente como um sistema de visão computacional identifica e localiza objetos. Este estudo percorre preparação de dados, anotações, treinamento, validação, teste, comparação de alternativas e interpretação das falhas.

As perguntas analisadas foram: (1) o ajuste fino melhora a detecção das classes selecionadas? (2) como o orçamento de 30 versus 60 épocas afeta qualidade e custo? (3) como o detector pré-treinado COCO se comporta sem personalização? (4) como uma CNN treinada do zero se compara quando a tarefa é classificação de imagem, e não localização?

2. Dados, procedência e anotação

2.1 Amostra usada

Foi selecionado um conjunto equilibrado de **80 imagens distintas** do split de validação do Open Images: 40 de Bottle e 40 de Coffee cup. As caixas de referência vieram das anotações públicas do dataset; foram preservados os endereços de origem, autores e licenças por imagem no arquivo de atribuição que acompanha o dataset.

As imagens foram obtidas pelas miniaturas oficiais do Open Images/Flickr, com dimensões entre 358 e 640 pixels por lado (média de 596 × 528). As 80 linhas do registro de origem indicam licença **Creative Commons Attribution 2.0 (CC BY 2.0)**. O dataset completo e seu registro de atribuição são entregues separadamente.

Partição	Bottle	Coffee cup	Total de imagens	Uso
Treino	32	32	64	Ajuste dos modelos
Validação	4	4	8	Comparação de épocas e seleção de checkpoint
Teste	4	4	8	Avaliação final, sem ajuste de hiperparâmetros
Total	**40**	**40**	**80**	-

A separação foi feita por imagem, sem reutilizar a mesma imagem em partições distintas. Os rótulos de detecção foram convertidos para o formato YOLO classe x_centro y_centro largura altura, com coordenadas normalizadas.

Partição	Instâncias de garrafa	Instâncias de xícara de café	Total de caixas
Treino	176	57	233
Validação	17	7	24
Teste	19	5	24

Assim, o balanceamento de **imagens** não implica balanceamento de **instâncias**: algumas imagens de garrafa contêm diversas caixas. A maior frequência de caixas de garrafa no treino não evitou o recall baixo dessa classe no teste; portanto, a contagem total, isoladamente, não explica o desempenho, e fatores visuais e de contexto podem contribuir.

2.2 Diferenças em relação ao enunciado

A amostra é pública e não foi anotada por este trabalho no Make Sense AI. O enunciado fornecido permite escolher o cenário e não exige fotografias próprias. Para manter a avaliação de detecção auditável, foram aproveitadas as caixas de referência já publicadas no Open Images. Essa substituição atende às quantidades e à comparação experimental, mas **não comprova a etapa de anotação manual no Make Sense AI exigida pelo enunciado**. As classes são Bottle e Coffee cup; não se deve generalizar o resultado para qualquer tipo de copo ou para outros domínios.

O mapeamento do detector COCO cup para Coffee cup também é aproximado: as taxonomias não são idênticas. Este fator limita a interpretação direta do baseline sem ajuste.

3. Métodos e protocolo

3.1 YOLOv5n adaptado

Usou-se YOLOv5n inicializado com pesos pré-treinados COCO e ajustado nas 64 imagens de treino. Foi mantida a mesma configuração entre experimentos: entrada 416 × 416, batch 8, semente 42, CPU, dois workers e early stopping desativado (patience=0). Variou-se o orçamento de épocas: 30 e 60. Como o escalonamento de learning rate depende desse limite, as trajetórias de otimização também diferem. Cada duração começou dos mesmos pesos iniciais COCO, não do checkpoint da outra simulação. A escolha de YOLOv5n, em vez de uma variante maior, reduziu custo num ambiente sem GPU; o modelo treinado tem 1,76 milhão de parâmetros e aproximadamente 4,1 GFLOPs na configuração indicada.

O checkpoint best.pt foi selecionado pelo desempenho de validação. A decisão comparativa favoreceu E60, que atingiu o melhor mAP@0,50:0,95 na validação. As métricas de teste foram calculadas depois da escolha, sem usar o teste para selecionar hiperparâmetros.

3.2 YOLO tradicional sem ajuste fino

Como baseline de integração rápida, aplicaram-se diretamente os pesos COCO pré-treinados do YOLOv5n às oito imagens de teste. Não houve fine-tuning com as imagens do projeto. Foram mantidas apenas detecções COCO bottle e cup; cup foi mapeada para coffee cup como aproximação explícita.

3.3 CNN do zero

A CNN foi inicializada aleatoriamente e treinada somente com as 64 imagens de treino para produzir uma classe por imagem. A arquitetura tem quatro blocos convolucionais (16, 32, 64 e 128 canais), ReLU, max-pooling, global average pooling, dropout de 0,4 e camada final de duas saídas. Foram aplicadas espelhamento horizontal e pequenas rotações, variação moderada de brilho/contraste e normalização apenas no treino; validação e teste receberam transformação determinística. O otimizador foi Adam com taxa inicial 0,001 e weight decay 0,0001; o limite era 50 épocas, com parada após dez épocas sem melhora na validação. A melhor combinação de acurácia e loss de validação ocorreu na época 37; o treinamento parou na época 47.

Essa rede **classifica a imagem inteira**; não prevê caixas nem localiza múltiplos objetos. Seus resultados, portanto, não são equivalentes às métricas de detecção dos modelos YOLO.

3.4 Métricas e comparação

Para detecção, reportam-se precision, recall, mAP@0,50 e mAP@0,50:0,95. IoU ≥ 0,50 define correspondência entre previsão e anotação. Na comparação harmonizada de teste, precision e recall são médias por classe; F1 macro é a média dos F1 calculados individualmente por classe usando confiança ≥ 0,25; AP50 é a área interpolada em 101 pontos, calculada no mesmo conjunto para os três detectores. Para CNN, reportam-se acurácia, precision/recall/F1 macro, cross-entropy e matriz de confusão por imagem.

Os tempos de treino são os informados pelo log de execução para YOLO e pelo cronômetro do script para CNN, sem incluir instalação de dependências ou download inicial de pesos. A latência dos detectores é uma média após aquecimento e três passagens pelas oito imagens, medindo o caminho de leitura/entrada, inferência e NMS do wrapper YOLO em CPU a 416 px. Para a CNN, a medida ponta a ponta inclui leitura, redimensionamento para 128 × 128, conversão/normalização e forward. A diferença de resolução e de tipo de saída impede interpretar latência como comparação isolada de eficiência arquitetural.

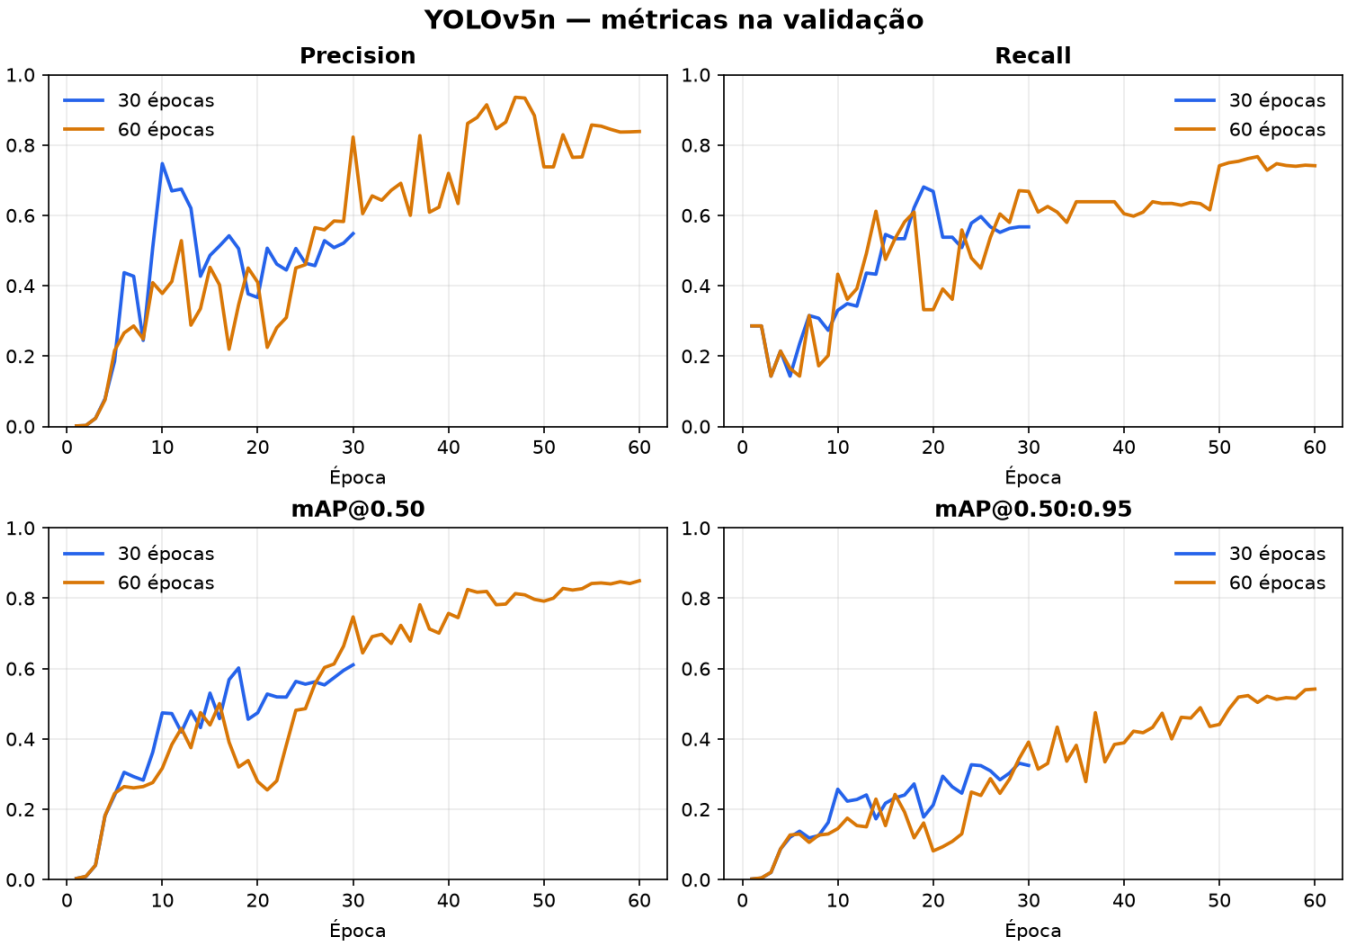
4. Resultados

4.1 YOLO: efeito de 30 versus 60 épocas

Valores de validação abaixo são do checkpoint best.pt após a validação final no split reservado para validação. As losses correspondem à última época registrada no treinamento.

Experimento	Melhor época (aprox.)	Precision val	Recall val	mAP50 val	mAP50-95 val	Loss de caixa treino/val	Tempo de treino
E30	29	0,535	0,567	0,599	0,328	0,0695 / 0,0511	1 min 44 s
E60	60	0,839	0,741	0,850	0,542	0,0571 / 0,0373	3 min 14 s

O treino por 60 épocas elevou mAP@0,50 em 0,251 e mAP@0,50:0,95 em 0,214 na validação, com maior precision e recall, ao custo de aproximadamente 90 segundos adicionais de treino. A redução da loss de caixa tanto em treino quanto em validação, somada à melhora das métricas de validação, não indica sobreajuste nesse ponto do experimento. Isso não garante generalização: o split tem somente oito imagens e o teste confirma uma queda relevante.



Curvas reais de validação do YOLOv5n nas duas durações

4.2 Avaliação em teste e comparação harmonizada dos detectores

A comparação abaixo usa as mesmas oito imagens, o mesmo pré-processamento, IoU 0,50 e limiar de confiança 0,25 para P/R/F1; mAP50 é calculado com a mesma implementação de 101 pontos. As latências são médias observadas em CPU; a variação entre os modelos YOLO é pequena diante do ruído de uma amostra tão curta.

Detector	P macro (conf. 0,25)	R macro (conf. 0,25)	F1 macro	mAP50 harmonizado	Latência média ± DP
YOLOv5n COCO sem ajuste	0,750	0,532	0,564	0,676	22,66 ± 2,06 ms/imagem
YOLOv5n ajustado, 30 épocas	0,375	0,605	0,423	0,551	23,51 ± 3,73 ms/imagem
YOLOv5n ajustado, 60 épocas	0,713	0,605	0,551	0,657	20,12 ± 1,70 ms/imagem

A avaliação nativa do val.py (que escolhe o ponto operacional da curva de confiança) para os checkpoints ajustados foi:

Modelo	Precision teste	Recall teste	mAP50 teste	mAP50-95 teste
E30	0,833	0,400	0,480	0,285
E60	0,694	0,605	0,614	0,411

As duas tabelas usam procedimentos de pontuação distintos: a comparação harmonizada fixa confiança em 0,25 e reporta P/R macro; val.py determina métricas agregadas conforme sua curva de confiança. Por isso, os respectivos P/R não devem ser misturados. A melhora de E60 sobre E30 aparece também no teste: mAP50 e mAP50-95 nativos aumentaram, e o recall passou de 0,400 para 0,605. A precision caiu de 0,833 para 0,694 no procedimento nativo, indicando o trade-off entre

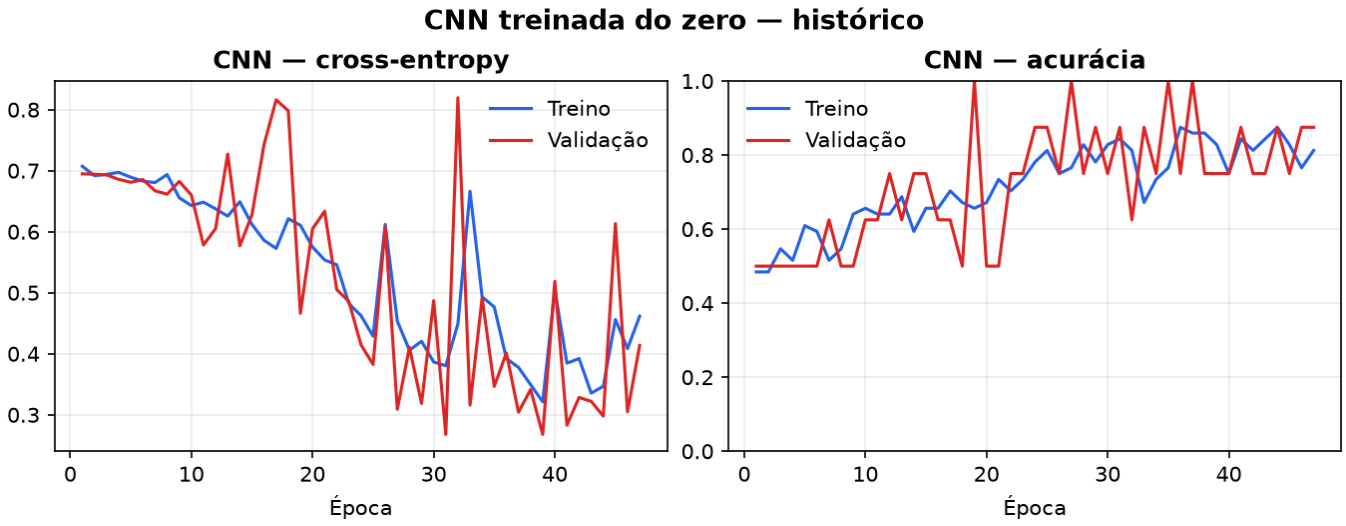
detecções perdidas e falsas detecções.

O baseline zero-shot teve o maior mAP50 harmonizado (0,676), apenas 0,019 acima do E60, enquanto E60 obteve F1 macro menor (0,551 contra 0,564) e recall macro maior (0,605 contra 0,532). O ajuste fino, portanto, aproximou o mAP do detector COCO e melhorou o recall macro no limiar fixado, sem superar o F1 macro do baseline, mas **não demonstrou superioridade absoluta em todas as métricas**. Para garrafas, persistiu recall baixo: no limiar 0,25, o E60 encontrou 4 de 19 instâncias e deixou 15 sem detecção; para xícaras, encontrou as 5 instâncias, com 3 falsos positivos. O baseline encontrou 5/19 garrafas e 4/5 xícaras. A distribuição de caixas no teste é desbalanceada e a pequena amostra torna cada erro influente.

4.3 CNN do zero

Métrica	Resultado
Melhor validação	Acurácia 1,000 (8/8), época 37; validação muito pequena
Teste	6/8 corretas; acurácia 0,750
Precision / recall / F1 macro no teste	0,750 / 0,750 / 0,750
Cross-entropy no teste	0,611
Matriz de confusão (real × previsto; ordem: bottle, coffee cup)	[[3, 1], [1, 3]]
Duração do treino	26,66 s, CPU, 47 épocas efetivamente executadas
Latência ponta a ponta	6,42 ± 0,67 ms/imagem, CPU, entrada 128 × 128

Uma imagem de cada classe foi classificada incorretamente. O resultado de 75% equivale a somente duas imagens erradas/certas de diferença em uma amostra de oito; não sustenta a alegação de desempenho amplo. A acurácia de validação perfeita em oito imagens não persistiu no teste, evidenciando variância alta e possível adaptação excessiva a uma validação diminuta, sem permitir confirmar a causa.



Curvas de treino e validação da CNN

4.4 Evidência qualitativa do teste

Na montagem, o turquesa mostra as caixas de referência e o laranja as caixas previstas pelo checkpoint de 60 épocas, com confiança mínima 0,25. As imagens ilustram acertos em xícaras e falhas/caixas insuficientes em cenas com várias garrafas. Essa inspeção complementa, mas não substitui, as métricas.



Predições reais do YOLOv5n de 60 épocas no conjunto de teste

5. Discussão comparativa

Critério	YOLO adaptado	YOLO COCO sem ajuste	CNN do zero
Facilidade de integração	Requer dataset de caixas, treinamento e validação; entrega classe e localização	Protótipo mais simples se as categorias genéricas cobrirem o domínio	Pipeline direto de classificação; precisa de classes em subpastas/labels e arquitetura
Qualidade observada	E60 melhora E30 e aproxima o baseline, mas mantém baixo recall de bottle	mAP50 maior no teste, porém recall macro inferior ao E60	75% de acurácia em 8 imagens; sem localização
Custo de customização	104 s (30 ep.) / 194 s (60 ep.) em CPU, fora instalação	Zero treino específico; peso inicial COCO precisa ser baixado	26,7 s em CPU; treinamento pequeno e sujeito a alta variância
Latência medida	Cerca de 20-24 ms/imagem a 416 px, com caminho YOLO completo	Cerca de 22,7 ms/imagem a 416 px	6,42 ms/imagem a 128 px, incluindo transformação e forward
Melhor aplicação no escopo	Localizar classes específicas quando há anotações suficientes	Referência rápida para classes cobertas pelo COCO	Classificar uma imagem com objeto dominante, quando não é necessário localizar

Não se deve comparar diretamente acurácia da CNN com mAP do detector: a CNN não retorna caixas. As medições de latência também foram feitas com resoluções distintas (416 para YOLO; 128 para CNN); o menor valor da CNN não demonstra superioridade intrínseca, pois a tarefa e o custo de pré-processamento diferem. Para comparar de modo rigoroso, seria necessário padronizar resolução, hardware, batching e fronteira de cronometragem.

6. Limitações e validade

1. **Amostra reduzida:** 80 imagens, apenas oito no teste; métricas variam muito com poucos exemplos e produzem incerteza elevada; intervalos de confiança seriam amplos.

2. **Instâncias desbalanceadas:** embora haja quatro imagens por classe no teste, são 19 caixas de garrafa e 5 de xícara. O desempenho agregado é sensível às imagens com múltiplas garrafas.

3. **Fonte distinta da entrega original:** os dados são públicos do Open Images e não foram rotulados neste trabalho no Make Sense AI. A exigência pendente é o uso do Make Sense; fotografias próprias não são obrigatórias no texto fornecido.

4. **Ontologia aproximada:** COCO cup não é idêntico à classe Open Images Coffee cup; resultados do baseline refletem também esse desalinhamento.

5. **Variância entre partições:** mAP50 do E60 caiu de 0,850 na validação para 0,614 no teste nativo. A diferença é compatível com amostra pequena, dificuldade desigual e possível sobreajuste; não é possível atribuir a causa com certeza.

6. **Hardware:** todos os tempos foram medidos em CPU no ambiente disponível; não representam latência em GPU, dispositivo móvel ou produção.

7. **Rotulagem e cobertura:** imagens públicas variam em fundo, escala, iluminação e número de objetos; apenas as duas classes-alvo foram consideradas.

7. Conclusão

O experimento foi executado de ponta a ponta sobre 80 imagens públicas licenciadas, com treino, validação e teste separados. Entre as duas configurações ajustadas, **60 épocas foi a melhor opção observada**: melhorou as métricas de validação, reduziu losses e superou E30 no mAP de teste, embora a precision nativa tenha sido menor. O detector COCO sem ajuste permaneceu competitivo e apresentou mAP50 ligeiramente maior na comparação harmonizada; por outro lado, o fine-tuning E60 melhorou recall macro, mas não o F1 macro do baseline nesse pequeno teste. A CNN do zero atingiu 75% de acurácia, mas resolve classificação por imagem e não localização, e sua validação perfeita não se sustentou no teste.

A evidência é adequada como demonstração acadêmica de pipeline e comparação crítica, não como validação de um sistema operacional. Antes de qualquer uso real, seria necessário ampliar a amostra, incluir mais condições e fontes independentes, revisar rótulos, medir em hardware-alvo e testar em dados externos. O uso de dados públicos não contraria uma exigência de fotos próprias, que não consta no enunciado fornecido. Ainda é necessário comprovar a rotulagem no Make Sense AI e completar a execução do notebook Colab, identificação, README com links e vídeo.

Referências

1. OPEN IMAGES. **Open Images V7: dataset, downloads and annotations**. Página oficial. Disponível em: https://storage.googleapis.com/openimages/web/download_v7.html. Acesso em 6 out. 2026.

2. Open Images. **Validation bounding-box annotations**. https://storage.googleapis.com/openimages/v5/validation-annotations-bbox.csv.

3. Open Images. **Validation images and metadata, including original source, author and license**. https://storage.googleapis.com/openimages/2018_04/validation/validation-images-with-rotation.csv.

4. Ultralytics. **Train YOLOv5 on Custom Data**. https://docs.ultralytics.com/yolov5/tutorials/train-custom-data. Acesso em 6 out. 2026.

5. Ultralytics. **YOLO Performance Metrics**. https://docs.ultralytics.com/guides/yolo-performance-metrics. Acesso em 6 out. 2026.

6. PyTorch. **Transfer Learning for Computer Vision Tutorial**. https://docs.pytorch.org/tutorials/beginner/transfer_learning_tutorial.html. Acesso em 6 out. 2026.

7. Ultralytics. **Repositório YOLOv5**. https://github.com/ultralytics/yolov5. Acesso em 6 out. 2026.

8. Reprodução e estado da entrega

O notebook NomeCompleto_rmXXXXX_pbl_fase6.ipynb implementa o fluxo de Drive, dependências, validação do dataset, dois treinos YOLO, comparação COCO, CNN, figuras e persistência. Suas células novas precisam ser executadas no Colab e salvas com as saídas antes da entrega. O notebook Fase6_FarmTech_Resultados_Verificados.ipynb contém análise executada dos resultados originais corrigidos. Novas execuções ficam em execucoes_novas, preservando os resultados originais.

O código usa caminhos configuráveis e fixa YOLOv5 v7.0 para reprodução futura. A versão/commit exatos da execução original não foram preservados como manifesto independente; portanto, não se promete reprodução numérica idêntica. O Colab deve registrar o commit efetivo e as versões instaladas.

Pendências pessoais e externas: inserir nome/RM; renomear notebook; executar e salvar saídas do Colab; revisar/rótular as imagens no Make Sense AI e guardar evidências; inserir URLs reais do repositório, Colab e vídeo não listado de até cinco minutos; tornar o GitHub público; enviar o link no portal até 13/10/2026, sem novos commits após a entrega.